

Causality for Data Scientists

Discovery, Causal Inference, and Applications in Machine Learning

Gustavo Ferreira Viegas de Oliveira

SBBD 2026

Universidade Federal de Viçosa (UFV)

NESPeD Lab

`gustavo.viegas@ufv.br`

1. Agenda

Agenda do minicurso

- 1 Motivação
- 2 Causalidade
- 3 Descoberta Causal
- 4 Inferência Causal
- 5 Ferramentas e Datasets
- 6 Explicabilidade Causal
- 7 Conclusão

Horário	Bloco	Conteúdo
14h – 16h	Parte 1	Fundamentos: grafos e causal discovery
16h – 16h30	<i>Coffee break</i>	
16h30 – 18h30	Parte 2	Causal inference e aplicações em ML

Práticas! Teremos notebooks práticos que rodam no Google Colab ou Jupyter Notebook.

github.com/gfviegas/causality-for-data-scientists-course

2. Sobre os autores

Quem está apresentando



Gustavo Ferreira Viegas de Oliveira (Apresentador)
[Lattes] [Linkedin]

Bacharel e mestre em Ciência da Computação pela Universidade Federal de Viçosa (UFV). Minha dissertação desenvolveu o Causal-Nest ([1]), framework que automatiza o pipeline de descoberta, estimação e refutação causal para profissionais de ML.
CTO e co-fundador da startup Hubs Contabilidade.

Fabrício Aguiar Silva [Lattes]

É doutor em Ciência da Computação pela UFMG (2015), com tese premiada como segunda melhor do Brasil pela SBC. Professor da UFV – Campus Florestal desde 2010, atua em inteligência artificial aplicada e sistemas distribuídos. Orientador de mestrado do apresentador.

Marcus Henrique Soares Mendes [Lattes]

É doutor em Engenharia Elétrica pela UFMG (2013) e Professor Titular da UFV – Campus Florestal desde 2005. Atua em otimização, computação evolutiva e meta-heurísticas. Co-orientador de mestrado do apresentador.

3. Motivação

ML é ótimo para associações

ML tradicional é excelente em perguntas como:

“O que costuma acontecer junto de X?”

ML tradicional é excelente em perguntas como:

“O que costuma acontecer junto de X ?”

Mas não é tão eficaz para perguntas do tipo:

- “O que acontece se eu intervir?” — $do(X)$
- “Quais atributos realmente causam esse resultado?”
- “O que precisaria mudar para o resultado ser diferente?”

Um exemplo clássico

Alarmes de incêndio estão fortemente correlacionados com a presença de bombeiros no local.

Associação $\neq$ Intervenção

Um exemplo clássico

Alarmes de incêndio estão fortemente correlacionados com a presença de bombeiros no local.

Intervenção é outra coisa

Instalar mais alarmes (*do*(alarme = ligado)) não traz mais bombeiros.

Associação $\neq$ Intervenção

Um exemplo clássico

Alarmes de incêndio estão fortemente correlacionados com a presença de bombeiros no local.

Intervenção é outra coisa

Instalar mais alarmes ($do(\text{alarme} = \text{ligado})$) não traz mais bombeiros.

$$P(Y | X) \neq P(Y | do(X))$$


Nicolas Cage causa afogamentos?



=



Correlação $\neq$ Causalidade



... e o que isso tem a ver com ciência de dados?

Duas variáveis podem ter uma associação em um sentido na população inteira, e no sentido oposto em *cada* subgrupo.

... e o que isso tem a ver com ciência de dados?

Duas variáveis podem ter uma associação em um sentido na população inteira, e no sentido oposto em *cada* subgrupo.

Esse cenário não é muito raro, e é consequência direta de confundimento (*confounding*).
Vamos ver?

3. Motivação

3.1. Paradoxo de Simpson

Mão na massa! → Notebook 1

`1_simpsons_paradox_example.ipynb`

4. Causalidade

- Causalidade é a relação entre causa e efeito;
- Aplicações relevantes na vida real: medicina, economia, política, etc.;
- Interesse crescente na área de pesquisa: Airbnb, Uber, Salesforce, Microsoft...

Adotar o estudo de causalidade permite melhorar a tomada de decisão, prever resultados de intervenções e entender relações complexas entre variáveis.

Pearl introduziu um framework formal para modelar intervenções:

- $P(Y | X)$ representa a probabilidade de Y dado que observamos X ;
- $P(Y | \text{do}(X))$ representa a probabilidade de Y quando intervenimos para fixar X em um valor específico;

Pearl introduziu um framework formal para modelar intervenções:

- $P(Y | X)$ representa a probabilidade de Y dado que observamos X ;
- $P(Y | \text{do}(X))$ representa a probabilidade de Y quando intervenimos para fixar X em um valor específico;
- $P(Y | X)$ reflete correlações que podem resultar de múltiplos caminhos causais.
- $P(Y | \text{do}(X))$ isola o efeito causal de X sobre Y simulando uma intervenção que elimina influências causais à X .

- $P(\textit{recuperou} \mid \textit{medicado})$ indica:

- $P(\textit{recuperou} \mid \textit{medicado})$ indica: correlação, possivelmente confundida por fatores como idade, gravidade da doença, etc.;

Interventions e o operador *do* — Um exemplo...

- $P(\textit{recuperou} \mid \textit{medicado})$ indica: correlação, possivelmente confundida por fatores como idade, gravidade da doença, etc.;
- $P(\textit{recuperou} \mid \textit{do}(\textit{medicado}))$ indica:

Interventions e o operador *do* — Um exemplo...

- $P(\textit{recuperou} \mid \textit{medicado})$ indica: correlação, possivelmente confundida por fatores como idade, gravidade da doença, etc.;
- $P(\textit{recuperou} \mid \textit{do}(\textit{medicado}))$ indica: o efeito causal do remédio na recuperação, isolando o impacto de outros fatores.

Interventions e o operador *do* — Um exemplo...


- $P(\textit{recuperou} \mid \textit{medicado})$ indica: correlação, possivelmente confundida por fatores como idade, gravidade da doença, etc.;
- $P(\textit{recuperou} \mid \textit{do}(\textit{medicado}))$ indica: o efeito causal do remédio na recuperação, isolando o impacto de outros fatores.

Podemos distinguir essas duas probabilidades coletando mais dados?

Interventions e o operador *do* — Um exemplo...


- $P(\text{recuperou} \mid \text{medicado})$ indica: correlação, possivelmente confundida por fatores como idade, gravidade da doença, etc.;
- $P(\text{recuperou} \mid \text{do}(\text{medicado}))$ indica: o efeito causal do remédio na recuperação, isolando o impacto de outros fatores.

Podemos distinguir essas duas probabilidades coletando mais dados?




Hierarquia Causal e os limites de ML tradicional


Aumento de habilidade cognitiva




- Nós = variáveis;
- Arestas dirigidas = causalidade direta;
- $X \rightarrow Y$: X é causa direta de Y




- Nós = variáveis;
- Arestas dirigidas = causalidade direta;
- $X \rightarrow Y$: X é causa direta de Y
- Como esses grafos são "criados"?



- Nós = variáveis;
- Arestas dirigidas = causalidade direta;
- $X \rightarrow Y$: X é causa direta de Y
- Como esses grafos são "criados"?
- Modelados por especialistas de negócios...




- Nós = variáveis;
 - Arestas dirigidas = causalidade direta;
 - $X \rightarrow Y$: X é causa direta de Y
-
- Como esses grafos são "criados"?
 - Modelados por especialistas de negócios...
 - ...ou descobertos a partir de algoritmos especializados (Causal Discovery).



Um *confounder* é uma causa comum do tratamento X e do resultado Y , representado por uma bifurcação no DAG: $X \leftarrow Z \rightarrow Y$.

Z cria uma associação espúria entre X e Y , mesmo que não haja relação causal direta entre eles.



(a) Confounder

$$X \leftarrow Z \rightarrow Y$$

Um *mediator* é uma variável que está no caminho causal entre X e Y , representado por uma cadeia no DAG: $X \rightarrow M \rightarrow Y$.

O mediador M transmite o efeito causal de X para Y .




(b) Mediator

$$X \rightarrow M \rightarrow Y$$

Um *collider* é uma variável que é causada por outras duas variáveis, representado por uma estrutura em "V" no DAG: $X \rightarrow C \leftarrow Y$.

Diferente dos confounders e mediators, um collider não transmite associação entre X e Y , por padrão: X e Y são independentes, a menos que condicionemos em C ou em um descendente de C .



(c) Collider

$$X \rightarrow K \leftarrow Y$$

Directional Separation (d-separation) é um critério para determinar independência condicional em DAGs.

Dois conjuntos de nós X e Y são d-separados por um conjunto de nós Z se todas as trilhas entre X e Y forem bloqueadas por Z .



(a) Chain

Blocked when $W \in Z$



(b) Fork

Blocked when $W \in Z$



(c) Collider

Blocked when $W \notin Z$;
opens when $W \in Z$

Múltiplos DAGs podem representar o mesmo conjunto de independências condicionais. Esses DAGs são chamados de *Markov equivalent*.




$X \perp Z$ significa que X é independente de Z .

$X \perp Z \mid Y$ significa que X é independente de Z dado Y .


$X \not\perp Z \mid Y$ significa que X não é independente de Z dado Y .

Equivalence class



Todos codificam $X \perp Z \mid Y$

V-structure



$X \perp Z$, mas $X \not\perp Z \mid Y$
(classe diferente)

4. Causalidade

4.1. Outros modelos causais

Dois frameworks algébricos complementam o modelo gráfico causal:

- **Structural Causal Models (SCMs)**, também de Pearl, descrevem relações causais usando equações estruturais, permitindo simulações e inferência causal;
- **Potential Outcomes**, de Rubin (também conhecido como *Rubin Causal Model*) aborda causalidade na perspectiva de comparações de contrafactuais, sendo mais utilizado em estatística e ciências sociais.

Dois frameworks algébricos complementam o modelo gráfico causal:

- **Structural Causal Models (SCMs)**, também de Pearl, descrevem relações causais usando equações estruturais, permitindo simulações e inferência causal;
- **Potential Outcomes**, de Rubin (também conhecido como *Rubin Causal Model*) aborda causalidade na perspectiva de comparações de contrafactuais, sendo mais utilizado em estatística e ciências sociais.

Os dois frameworks são complementares: SCMs fornece linguagem gráfica para codificar sobre a estrutura causal, e Potential Outcomes fornece estimandos e estratégias de estimativas causais.

Para cada unidade i e um valor de tratamento t , existe um **resultado potencial** $Y_i(t)$, que representa o resultado que seria observado se a unidade i recebesse o tratamento t .

Para cada unidade i e um valor de tratamento t , existe um **resultado potencial** $Y_i(t)$, que representa o resultado que seria observado se a unidade i recebesse o tratamento t .

O efeito causal para a unidade i é $\tau_i = Y_i(1) - Y_i(0)$: a diferença entre o resultado potencial sob tratamento e o resultado potencial sob controle.

Para cada unidade i e um valor de tratamento t , existe um **resultado potencial** $Y_i(t)$, que representa o resultado que seria observado se a unidade i recebesse o tratamento t .

O efeito causal para a unidade i é $\tau_i = Y_i(1) - Y_i(0)$: a diferença entre o resultado potencial sob tratamento e o resultado potencial sob controle.


No exemplo da vacinação, $Y_i(1)$ representa a probabilidade de recuperação se a pessoa for vacinada, e $Y_i(0)$ representa a probabilidade de recuperação se a pessoa não for vacinada.

5. Descoberta Causal

Descoberta Causal

Causal Discovery (CD) é o processo de aprender estruturas causais a partir de dados observacionais, sem depender de conhecimento de negócio (nem sempre é possível realizar experimentos).

A partir de dados observacionais, o objetivo é inferir um grafo causal (ou classe de equivalência) que represente as relações causais.



Dados observacionais sozinhos geralmente identifica apenas a classe de equivalência representado por um *CPDAG* (Completed Partially Directed Acyclic Graph) e não um único DAG.

Dados observacionais sozinhos geralmente identifica apenas a classe de equivalência representado por um *CPDAG* (Completed Partially Directed Acyclic Graph) e não um único DAG.

O problema é muito desafiador por diversos motivos:

- O espaço de busca de possíveis grafos cresce super-exponencialmente com o número de variáveis;

Dados observacionais sozinhos geralmente identifica apenas a classe de equivalência representado por um *CPDAG* (Completed Partially Directed Acyclic Graph) e não um único DAG.

O problema é muito desafiador por diversos motivos:

- O espaço de busca de possíveis grafos cresce super-exponencialmente com o número de variáveis;
- Amostras finitas podem fornecer estimativas não confiáveis de independências condicionais;

Dados observacionais sozinhos geralmente identifica apenas a classe de equivalência representado por um *CPDAG* (Completed Partially Directed Acyclic Graph) e não um único DAG.

O problema é muito desafiador por diversos motivos:

- O espaço de busca de possíveis grafos cresce super-exponencialmente com o número de variáveis;
- Amostras finitas podem fornecer estimativas não confiáveis de independências condicionais;
- A presença de variáveis latentes (não observadas) pode impedir que a verdadeira estrutura seja identificada apenas com dados.

- **Constraint-based:** Utiliza testes de independência condicional para inferir a estrutura causal. Exemplo: PC, FCI.

- **Constraint-based:** Utiliza testes de independência condicional para inferir a estrutura causal. Exemplo: PC, FCI.
- **Score-based:** Busca por uma estrutura que maximize uma função de pontuação (score) equilibrando fit e complexidade. Exemplo: GES, BIC.

- **Constraint-based:** Utiliza testes de independência condicional para inferir a estrutura causal. Exemplo: PC, FCI.
- **Score-based:** Busca por uma estrutura que maximize uma função de pontuação (score) equilibrando fit e complexidade. Exemplo: GES, BIC.
- **Functional:** Explora assimetrias na forma funcional de relações entre variáveis para inferir causalidade. Exemplo: LiNGAM, ANM. - Assumem relações lineares e sem ruído gaussiano, podendo identificar até um DAG completo, se as premissas forem atendidas.

- **Constraint-based:** Utiliza testes de independência condicional para inferir a estrutura causal. Exemplo: PC, FCI.
- **Score-based:** Busca por uma estrutura que maximize uma função de pontuação (score) equilibrando fit e complexidade. Exemplo: GES, BIC.
- **Functional:** Explora assimetrias na forma funcional de relações entre variáveis para inferir causalidade. Exemplo: LiNGAM, ANM. - Assumem relações lineares e sem ruído gaussiano, podendo identificar até um DAG completo, se as premissas forem atendidas.
- **Hybrid:** Combina elementos de diferentes abordagens.



Escolher um algoritmo de CD depende de características como:

- Tamanho do conjunto de dados (número de amostras e variáveis);



Escolher um algoritmo de CD depende de características como:

- Tamanho do conjunto de dados (número de amostras e variáveis);
- Premissas sobre a distribuição dos dados (linearidade, ruído, etc.);



Escolher um algoritmo de CD depende de características como:

- Tamanho do conjunto de dados (número de amostras e variáveis);
- Premissas sobre a distribuição dos dados (linearidade, ruído, etc.);
- Tipos de dados suportados (contínuos, discretos);



Escolher um algoritmo de CD depende de características como:

- Tamanho do conjunto de dados (número de amostras e variáveis);
- Premissas sobre a distribuição dos dados (linearidade, ruído, etc.);
- Tipos de dados suportados (contínuos, discretos);
- Robustez a ruído e outliers.



Escolher um algoritmo de CD depende de características como:

- Tamanho do conjunto de dados (número de amostras e variáveis);
- Premissas sobre a distribuição dos dados (linearidade, ruído, etc.);
- Tipos de dados suportados (contínuos, discretos);
- Robustez a ruído e outliers.

Não existe bala de prata.

Na prática, é comum testar vários e buscar um consenso ou utilizar conhecimento de negócio para validar os resultados.

Algorithm	Full Name	Supported Data Types	Gaussian Assumption	Family
PC [2]	Peter-Clark	C, D	No	Constraint
GS [3]	Grow-Shrink	C, D	No	Constraint
IAMB [4]	Incremental Assoc. Markov Blanket	C, D	No	Constraint
Fast-IAMB [5]	Fast Markov Blanket	C, D	No	Constraint
Inter-IAMB [5]	Interleaved Markov Blanket	C, D	No	Constraint
MMPC [6]	Max-Min Parents and Children	C, D	No	Constraint
GES [7]	Greedy Equivalence Search	C, D	Yes	Score
GIES [8]	Greedy Interv. Equivalence Search	C, D	Yes	Score
CCDr [9]	Concave penalized Coord. Descent	C	Yes	Score
BES [10]	Bayesian Equivalence Search	C, D	Yes	Score
CGNN [11]	Causal Generative Neural Networks	C	No	Score
SAM [12]	Structural Agnostic Model	C	No	Score
LiNGAM [13]	Linear Non-Gaussian Acyclic Model	C	No*	Functional
CAM [14]	Causal Additive Models	C	Yes	Functional
GRaSP [15]	Greedy Relax. of Sparsest Perm.	C, D	No	Hybrid

* LiNGAM assumes linear relationships with non-Gaussian noise.

Mão na massa! → Notebook 2


`2_causal_discovery.ipynb`

6. Inferência Causal

Inferência Causal

Causal Discovery (CD) aprende a estrutura de relações causais. Causal Inference (CI) estima a magnitude dos efeitos causais.

CI responde perguntas como "Qual é o efeito do tratamento X no resultado Y ?".



Antes de calcular qualquer coisa, precisamos responder uma pergunta mais básica: **dá pra calcular esse efeito com os dados que eu tenho?**

Antes de calcular qualquer coisa, precisamos responder uma pergunta mais básica: **dá pra calcular esse efeito com os dados que eu tenho?**

Um efeito é *identificável* se puder ser determinado unicamente a partir dos dados observacionais e do grafo causal. Se o grafo tiver um confundidor que você não mediu, por exemplo, a resposta pode ser **não**. Não importa o quão sofisticado seja o seu método depois.

Antes de calcular qualquer coisa, precisamos responder uma pergunta mais básica: **dá pra calcular esse efeito com os dados que eu tenho?**

Um efeito é *identificável* se puder ser determinado unicamente a partir dos dados observacionais e do grafo causal. Se o grafo tiver um confundidor que você não mediu, por exemplo, a resposta pode ser **não**. Não importa o quão sofisticado seja o seu método depois.

Na prática, quem responde essa pergunta é o *do-calculus* de Pearl: um conjunto de regras formais para isso. Não vamos entrar nas regras; o que importa é a ideia: **identificação vem antes de estimação**.

Inferência Causal – O que esse número quer dizer?

Lembra do efeito individual $\tau_i = Y_i(1) - Y_i(0)$ da seção anterior? O **ATE** (Average Treatment Effect) é só a média disso para todo mundo:

τ = média de τ_i na população

Lembra do efeito individual $\tau_i = Y_i(1) - Y_i(0)$ da seção anterior? O **ATE** (Average Treatment Effect) é só a média disso para todo mundo:

τ = média de τ_i na população

Isso é um número que você pode interpretar direto, como uma métrica de negócio. Ex: efeito de um programa de treinamento profissional no salário anual.

Lembra do efeito individual $\tau_i = Y_i(1) - Y_i(0)$ da seção anterior? O **ATE** (Average Treatment Effect) é só a média disso para todo mundo:

τ = média de τ_i na população

Isso é um número que você pode interpretar direto, como uma métrica de negócio. Ex: efeito de um programa de treinamento profissional no salário anual.

- $\tau = \$20.000$

Inferência Causal — O que esse número quer dizer?

Lembra do efeito individual $\tau_i = Y_i(1) - Y_i(0)$ da seção anterior? O **ATE** (Average Treatment Effect) é só a média disso para todo mundo:

τ = média de τ_i na população

Isso é um número que você pode interpretar direto, como uma métrica de negócio. Ex: efeito de um programa de treinamento profissional no salário anual.

- $\tau = \$20.000 \rightarrow$ o programa muda a vida da pessoa;
- $\tau = \$1.794$

Inferência Causal — O que esse número quer dizer?

Lembra do efeito individual $\tau_i = Y_i(1) - Y_i(0)$ da seção anterior? O **ATE** (Average Treatment Effect) é só a média disso para todo mundo:

τ = média de τ_i na população

Isso é um número que você pode interpretar direto, como uma métrica de negócio. Ex: efeito de um programa de treinamento profissional no salário anual.

- $\tau = \$20.000 \rightarrow$ o programa muda a vida da pessoa;
- $\tau = \$1.794 \rightarrow$ efeito modesto, só algumas semanas de salário a mais por ano;
- $\tau = \$2$

Inferência Causal — O que esse número quer dizer?

Lembra do efeito individual $\tau_i = Y_i(1) - Y_i(0)$ da seção anterior? O **ATE** (Average Treatment Effect) é só a média disso para todo mundo:

τ = média de τ_i na população

Isso é um número que você pode interpretar direto, como uma métrica de negócio. Ex: efeito de um programa de treinamento profissional no salário anual.

- $\tau = \$20.000 \rightarrow$ o programa muda a vida da pessoa;
- $\tau = \$1.794 \rightarrow$ efeito modesto, só algumas semanas de salário a mais por ano;
- $\tau = \$2 \rightarrow$ estatisticamente é ruído, não é um efeito de verdade;
- $\tau = -\$500$

Inferência Causal — O que esse número quer dizer?

Lembra do efeito individual $\tau_i = Y_i(1) - Y_i(0)$ da seção anterior? O **ATE** (Average Treatment Effect) é só a média disso para todo mundo:

τ = média de τ_i na população

Isso é um número que você pode interpretar direto, como uma métrica de negócio. Ex: efeito de um programa de treinamento profissional no salário anual.

- $\tau = \$20.000 \rightarrow$ o programa muda a vida da pessoa;
- $\tau = \$1.794 \rightarrow$ efeito modesto, só algumas semanas de salário a mais por ano;
- $\tau = \$2 \rightarrow$ estatisticamente é ruído, não é um efeito de verdade;
- $\tau = -\$500 \rightarrow$ o programa parece estar *piorando* a vida das pessoas.

Resposta curta: **confundimento** (aquele fork que vimos antes: $X \leftarrow Z \rightarrow Y$).

Resposta curta: **confundimento** (aquele fork que vimos antes: $X \leftarrow Z \rightarrow Y$).

Suponha os dados:

- Média(salário | fez o programa) — Média(salário | não fez) = **−\$8.497**

Resposta curta: **confundimento** (aquele fork que vimos antes: $X \leftarrow Z \rightarrow Y$).

Suponha os dados:

- Média(salário | fez o programa) — Média(salário | não fez) = $-\$8.497$ (!)
- Efeito causal real, medido em um experimento controlado: $\tau = \$1.794$

Resposta curta: **confundimento** (aquele fork que vimos antes: $X \leftarrow Z \rightarrow Y$).

Suponha os dados:

- Média(salário | fez o programa) — Média(salário | não fez) = $-\$8.497$ (!)
- Efeito causal real, medido em um experimento controlado: $\tau = \$1.794$

A comparação direta não só erra o valor, ela erra o **sinal**. Quem fez o programa, na média, já ganhava menos antes de entrar nele;

Comparar as médias brutas confunde "efeito do programa" com "quem tende a se inscrever no programa".

A ideia por trás de (quase) todo estimador é a mesma: **comparar pessoas parecidas entre si**, e só depois olhar a diferença de tratamento. Não vamos ver as fórmulas, só a lógica de cada um:

A ideia por trás de (quase) todo estimador é a mesma: **comparar pessoas parecidas entre si**, e só depois olhar a diferença de tratamento. Não vamos ver as fórmulas, só a lógica de cada um:

- **Ajuste por regressão**: aprende um modelo do resultado e usa ele pra simular “e se essa pessoa tivesse (ou não) feito o tratamento?”;

A ideia por trás de (quase) todo estimador é a mesma: **comparar pessoas parecidas entre si**, e só depois olhar a diferença de tratamento. Não vamos ver as fórmulas, só a lógica de cada um:

- **Ajuste por regressão**: aprende um modelo do resultado e usa ele pra simular "e se essa pessoa tivesse (ou não) feito o tratamento?";
- **Pareamento (*matching*)**: pra cada pessoa tratada, acha um "gêmeo estatístico" não tratado (o mais parecido possível) e compara os dois;

A ideia por trás de (quase) todo estimador é a mesma: **comparar pessoas parecidas entre si**, e só depois olhar a diferença de tratamento. Não vamos ver as fórmulas, só a lógica de cada um:

- **Ajuste por regressão**: aprende um modelo do resultado e usa ele pra simular "e se essa pessoa tivesse (ou não) feito o tratamento?";
- **Pareamento (*matching*)**: pra cada pessoa tratada, acha um "gêmeo estatístico" não tratado (o mais parecido possível) e compara os dois;
- **Score de propensão / IPW**: dá mais peso a quem é "raro" no seu grupo, pra reequilibrar a comparação;

A ideia por trás de (quase) todo estimador é a mesma: **comparar pessoas parecidas entre si**, e só depois olhar a diferença de tratamento. Não vamos ver as fórmulas, só a lógica de cada um:

- **Ajuste por regressão**: aprende um modelo do resultado e usa ele pra simular "e se essa pessoa tivesse (ou não) feito o tratamento?";
- **Pareamento (*matching*)**: pra cada pessoa tratada, acha um "gêmeo estatístico" não tratado (o mais parecido possível) e compara os dois;
- **Score de propensão / IPW**: dá mais peso a quem é "raro" no seu grupo, pra reequilibrar a comparação;
- **Estimadores duplamente robustos**: usa duas das ideias acima ao mesmo tempo, como uma rede de segurança: se uma errar, a outra ainda salva a estimativa.

Em ML, temos dois tipos de métrica:

- **Padronizadas:** acurácia, AUC, F1, R^2 ... vivem numa escala fixa e dá pra comparar entre problemas diferentes, mais ou menos;

Em ML, temos dois tipos de métrica:

- **Padronizadas:** acurácia, AUC, F1, R^2 ... vivem numa escala fixa e dá pra comparar entre problemas diferentes, mais ou menos;
- **Na escala bruta:** RMSE, MAE... um RMSE de 5 não quer dizer nada sozinho, depende da unidade do que você está prevendo.

Em ML, temos dois tipos de métrica:

- **Padronizadas:** acurácia, AUC, F1, R^2 ... vivem numa escala fixa e dá pra comparar entre problemas diferentes, mais ou menos;
- **Na escala bruta:** RMSE, MAE... um RMSE de 5 não quer dizer nada sozinho, depende da unidade do que você está prevendo.

O efeito causal (τ) é sempre do segundo tipo. Ele vive na escala original do resultado Y . Não existe uma versão “padronizada e universal” por padrão.

Em ML, temos dois tipos de métrica:

- **Padronizadas:** acurácia, AUC, F1, R^2 ... vivem numa escala fixa e dá pra comparar entre problemas diferentes, mais ou menos;
- **Na escala bruta:** RMSE, MAE... um RMSE de 5 não quer dizer nada sozinho, depende da unidade do que você está prevendo.

O efeito causal (τ) é sempre do segundo tipo. Ele vive na escala original do resultado Y . Não existe uma versão “padronizada e universal” por padrão.

- $\tau = 1.794$ em dólares de salário $\neq \tau = 1.794$ em mmHg de pressão $\neq \tau = 1.794$ em cliques de anúncio;

Em ML, temos dois tipos de métrica:

- **Padronizadas:** acurácia, AUC, F1, R^2 ... vivem numa escala fixa e dá pra comparar entre problemas diferentes, mais ou menos;
- **Na escala bruta:** RMSE, MAE... um RMSE de 5 não quer dizer nada sozinho, depende da unidade do que você está prevendo.

O efeito causal (τ) é sempre do segundo tipo. Ele vive na escala original do resultado Y . Não existe uma versão “padronizada e universal” por padrão.

- $\tau = 1.794$ em dólares de salário $\neq \tau = 1.794$ em mmHg de pressão $\neq \tau = 1.794$ em cliques de anúncio;
- O mesmo número pode ser **enorme** num contexto e **irrelevante** em outro.

Em ML, temos dois tipos de métrica:

- **Padronizadas:** acurácia, AUC, F1, R^2 ... vivem numa escala fixa e dá pra comparar entre problemas diferentes, mais ou menos;
- **Na escala bruta:** RMSE, MAE... um RMSE de 5 não quer dizer nada sozinho, depende da unidade do que você está prevendo.

O efeito causal (τ) é sempre do segundo tipo. Ele vive na escala original do resultado Y . Não existe uma versão “padronizada e universal” por padrão.

- $\tau = 1.794$ em dólares de salário $\neq \tau = 1.794$ em mmHg de pressão $\neq \tau = 1.794$ em cliques de anúncio;
- O mesmo número pode ser **enorme** num contexto e **irrelevante** em outro.

$\tau_{\text{Grafo A}} > \tau_{\text{Grafo B}}$ **não** necessariamente significa “o efeito em A é maior”.

Inferência Causal — Como confiar no número?

Diferente de um modelo preditivo, aqui não existe um "conjunto de teste" óbvio pra validar a resposta.

Afinal, nós nunca observamos o contrafactual.

Então, em vez de provar que a estimativa está certa, tentamos **quebrar ela** de propósito.




- **Teste placebo:** aplique o mesmo método em algo que você *sabe* que não tem efeito nenhum (ex: um tratamento sorteado aleatoriamente). Se o método “encontra” um efeito mesmo assim, desconfie dele;

- **Teste placebo:** aplique o mesmo método em algo que você *sabe* que não tem efeito nenhum (ex: um tratamento sorteado aleatoriamente). Se o método "encontra" um efeito mesmo assim, desconfie dele;
- **Subconjuntos de dados:** repita a análise em pedaços diferentes dos dados. Se o número fica pulando de um lado pro outro, sua estimativa não é tão sólida quanto parece;

- **Teste placebo:** aplique o mesmo método em algo que você *sabe* que não tem efeito nenhum (ex: um tratamento sorteado aleatoriamente). Se o método “encontra” um efeito mesmo assim, desconfie dele;
- **Subconjuntos de dados:** repita a análise em pedaços diferentes dos dados. Se o número fica pulando de um lado pro outro, sua estimativa não é tão sólida quanto parece;
- **Causa comum aleatória:** adicione uma variável de ruído qualquer, como se fosse um confundidor. Um bom método deve ignorar ela e manter a estimativa praticamente igual.

- **Teste placebo:** aplique o mesmo método em algo que você *sabe* que não tem efeito nenhum (ex: um tratamento sorteado aleatoriamente). Se o método “encontra” um efeito mesmo assim, desconfie dele;
- **Subconjuntos de dados:** repita a análise em pedaços diferentes dos dados. Se o número fica pulando de um lado pro outro, sua estimativa não é tão sólida quanto parece;
- **Causa comum aleatória:** adicione uma variável de ruído qualquer, como se fosse um confundidor. Um bom método deve ignorar ela e manter a estimativa praticamente igual.

Nenhum desses testes *prova* que a estimativa está certa, só avaliam sua confiança nela.



Mão na massa! → Notebook 3

`3_causal_estimation.ipynb`

Inferência Causal — E se o efeito não for igual pra todo mundo?

O ATE é uma média sobre toda a população. Só que médias escondem coisa.

Inferência Causal — E se o efeito não for igual pra todo mundo?

O ATE é uma média sobre toda a população. Só que médias escondem coisa.

Imagine um tratamento que ajuda metade das pessoas e atrapalha a outra metade, na mesma proporção.

Inferência Causal — E se o efeito não for igual pra todo mundo?

O ATE é uma média sobre toda a população. Só que médias escondem coisa.

Imagine um tratamento que ajuda metade das pessoas e atrapalha a outra metade, na mesma proporção. O ATE dá quase zero

Inferência Causal — E se o efeito não for igual pra todo mundo?


O ATE é uma média sobre toda a população. Só que médias escondem coisa.

Imagine um tratamento que ajuda metade das pessoas e atrapalha a outra metade, na mesma proporção. O ATE dá quase zero mas não porque o tratamento não faz nada, e sim porque os efeitos opostos se cancelam.

Inferência Causal — E se o efeito não for igual pra todo mundo?

O ATE é uma média sobre toda a população. Só que médias escondem coisa.

Imagine um tratamento que ajuda metade das pessoas e atrapalha a outra metade, na mesma proporção. O ATE dá quase zero mas não porque o tratamento não faz nada, e sim porque os efeitos opostos se cancelam.



O **CATE** (*Conditional Average Treatment Effect*) responde: qual o efeito do tratamento, condicionado nas covariáveis X ?

$$\tau(x) = \mathbb{E}[Y(1) - Y(0) \mid X = x]$$

O **CATE** (*Conditional Average Treatment Effect*) responde: qual o efeito do tratamento, condicionado nas covariáveis X ?

$$\tau(x) = \mathbb{E}[Y(1) - Y(0) \mid X = x]$$

É a mesma ideia do ATE que você já viu, só que calculada separadamente pra cada perfil de unidade, em vez de uma média só pra todo mundo.

O **CATE** (*Conditional Average Treatment Effect*) responde: qual o efeito do tratamento, condicionado nas covariáveis X ?

$$\tau(x) = \mathbb{E}[Y(1) - Y(0) \mid X = x]$$

É a mesma ideia do ATE que você já viu, só que calculada separadamente pra cada perfil de unidade, em vez de uma média só pra todo mundo.

Com isso dá pra tomar uma decisão **personalizada**: trate a unidade i só se $\hat{\tau}(x_i) > 0$. Situações assim são comuns em saúde (um remédio ajuda um genótipo e prejudica outro) e marketing (uma promoção atrai quem é sensível a preço e irrita quem já é cliente fiel).

A ideia por trás dos métodos mais comuns (*meta-learners*) reaproveita os mesmos estimadores de ATE que você já viu, só que combinados de um jeito diferente:

- **S-learner**: um modelo só, com o tratamento como mais uma variável;

A ideia por trás dos métodos mais comuns (*meta-learners*) reaproveita os mesmos estimadores de ATE que você já viu, só que combinados de um jeito diferente:

- **S-learner:** um modelo só, com o tratamento como mais uma variável;
- **T-learner:** dois modelos separados, um pra cada braço do tratamento;

A ideia por trás dos métodos mais comuns (*meta-learners*) reaproveita os mesmos estimadores de ATE que você já viu, só que combinados de um jeito diferente:

- **S-learner**: um modelo só, com o tratamento como mais uma variável;
- **T-learner**: dois modelos separados, um pra cada braço do tratamento;
- **X-learner**: usa os dois modelos do T-learner pra imputar o efeito individual, útil quando os grupos são desbalanceados.

Notebook extra!

Caso queira aprofundar nesse assunto, veja o notebook extra #5.


7. Ferramentas e Datasets

Você já viu o pipeline inteiro: descoberta, identificação, estimação, refutação.

Ferramentas e Datasets

Você já viu o pipeline inteiro: descoberta, identificação, estimação, refutação.

Pergunta que todo mundo faz depois de um curso de causalidade: **“beleza, mas eu clico em quê pra fazer isso?”**



Ferramenta	Descoberta	Estimação	Refutação	Interface	Paralelo
CDT [16]	✓	–	–	–	–
causal-learn [17]	✓	–	–	–	–
bnlearn [18]	✓	–	–	–	–
Tetrad [19]	✓	–	–	✓	–
gCastle [20]	✓	–	–	–	–
DoWhy [21]	–	✓	✓	–	–
EconML [22]	–	✓	–	–	–
CausalML [23]	–	✓	–	–	✓
CausalNex [24]	✓	✓	–	–	–
Salesforce CausalAI [25]	✓	–	–	✓	✓
<i>Causal-Nest</i> [1]	✓	✓	✓	–	✓

Repara no padrão da tabela:

Repara no padrão da tabela: praticamente ninguém faz tudo.

Repara no padrão da tabela: praticamente ninguém faz tudo.

- Ferramentas de **descoberta** (CDT, causal-learn, bnlearn, Tetrad, gCastle) sabem achar a estrutura, mas não estimam nem refutam nada;

Repara no padrão da tabela: praticamente ninguém faz tudo.

- Ferramentas de **descoberta** (CDT, causal-learn, bnlearn, Tetrad, gCastle) sabem achar a estrutura, mas não estimam nem refutam nada;
- Ferramentas de **inferência** (DoWhy, EconML, CausalML) já assumem que você chegou com um grafo pronto na mão.
- Alguns backends em R; as representações de grafo são diferentes, etc.

Repara no padrão da tabela: praticamente ninguém faz tudo.

- Ferramentas de **descoberta** (CDT, causal-learn, bnlearn, Tetrad, gCastle) sabem achar a estrutura, mas não estimam nem refutam nada;
- Ferramentas de **inferência** (DoWhy, EconML, CausalML) já assumem que você chegou com um grafo pronto na mão.
- Alguns backends em R; as representações de grafo são diferentes, etc.

Na prática, isso significa juntar ferramentas diferentes manualmente: converter formato de dado, e torcer pra estrutura descoberta bater com o que a ferramenta de inferência espera.

Repara no padrão da tabela: praticamente ninguém faz tudo.

- Ferramentas de **descoberta** (CDT, causal-learn, bnlearn, Tetrad, gCastle) sabem achar a estrutura, mas não estimam nem refutam nada;
- Ferramentas de **inferência** (DoWhy, EconML, CausalML) já assumem que você chegou com um grafo pronto na mão.
- Alguns backends em R; as representações de grafo são diferentes, etc.

Na prática, isso significa juntar ferramentas diferentes manualmente: converter formato de dado, e torcer pra estrutura descoberta bater com o que a ferramenta de inferência espera.

O *Causal-Nest* (projeto do autor) é uma tentativa de unificar esse pipeline inteiro numa única interface.

Em ML supervisionado, você tem o rótulo verdadeiro pra comparar. Em CD, isso quase nunca acontece: o grafo causal “de verdade” por trás de um dataset observacional raramente é conhecido com certeza.

Em ML supervisionado, você tem o rótulo verdadeiro pra comparar. Em CD, isso quase nunca acontece: o grafo causal “de verdade” por trás de um dataset observacional raramente é conhecido com certeza.

O **Sachs**, que a gente usou lá no Notebook 2, é a exceção rara: um dos poucos datasets reais com grafo verdadeiro validado por experimentos de intervenção de verdade.


Em ML supervisionado, você tem o rótulo verdadeiro pra comparar. Em CD, isso quase nunca acontece: o grafo causal “de verdade” por trás de um dataset observacional raramente é conhecido com certeza.

O **Sachs**, que a gente usou lá no Notebook 2, é a exceção rara: um dos poucos datasets reais com grafo verdadeiro validado por experimentos de intervenção de verdade.

A grande maioria dos outros benchmarks conhecidos não tem um grafo completo. Eles trazem, no máximo, pistas parciais: ordem temporal entre variáveis, ou uma lista de arestas proibidas e obrigatórias.


O “Expert” no meio do pipeline?

Lembra dessa figura?



O “Expert” no meio do pipeline?


Lembra dessa figura?



Sem dataset de gabarito pra validar automaticamente, alguém precisa olhar o grafo e dizer “faz sentido” ou “essa seta tá errada”.

O “Expert” no meio do pipeline?

Lembra dessa figura?



Sem dataset de gabarito pra validar automaticamente, alguém precisa olhar o grafo e dizer “faz sentido” ou “essa seta tá errada”.

Na prática, CD quase sempre entrega uma sugestão, não uma resposta final. Um humano com conhecimento de domínio é necessário pra ter uma resposta causal válida de fato.

Quer dizer que é inútil sem um especialista?



Quer dizer que é inútil sem um especialista?



NÃO!

Mesmo sem um especialista, a análise automatizada de causalidade pode ser útil para melhorar a compreensão do problema, gerar hipóteses, e até mesmo melhorar modelos preditivos.

Quer dizer que é inútil sem um especialista?



NÃO!

Mesmo sem um especialista, a análise automatizada de causalidade pode ser útil para melhorar a compreensão do problema, gerar hipóteses, e até mesmo melhorar modelos preditivos.

Afinal, modelos baseados apenas em correlação não são úteis?

Mão na massa! → Notebook 4

`4_causal_feature_selection.ipynb`

8. Explicabilidade Causal

Lembra da Hierarquia Causal?

Lembra da Hierarquia Causal? O nível 3, *counterfactual*, pergunta “e se eu tivesse agido diferente?”.

É exatamente a pergunta que aparece quando alguém quer entender (ou contestar) uma decisão automatizada.

Lembra da Hierarquia Causal? O nível 3, *counterfactual*, pergunta “e se eu tivesse agido diferente?”.

É exatamente a pergunta que aparece quando alguém quer entender (ou contestar) uma decisão automatizada.

Duas famílias de explicação, duas perguntas bem diferentes:

- **SHAP** (atribuição): “o que pesou nessa previsão?”;


Lembra da Hierarquia Causal? O nível 3, *counterfactual*, pergunta “e se eu tivesse agido diferente?”.

É exatamente a pergunta que aparece quando alguém quer entender (ou contestar) uma decisão automatizada.

Duas famílias de explicação, duas perguntas bem diferentes:

- **SHAP** (atribuição): “o que pesou nessa previsão?”;
- **DiCE** (contrafactual): “o que eu precisaria mudar pra mudar o resultado?”.


Explicabilidade Causal – SHAP vs. Contrafactual, num exemplo real



Esse é um SHAP *waterfall* de um pedido de crédito negado.

Ele diz o que “pesou” na decisão do modelo...


Explicabilidade Causal – SHAP vs. Contrafactual, num exemplo real



Esse é um SHAP *waterfall* de um pedido de crédito negado.

Ele diz o que “pesou” na decisão do modelo... mas não diz o que fazer a respeito.

Explicabilidade Causal – SHAP vs. Contrafactual, num exemplo real



Esse é um SHAP *waterfall* de um pedido de crédito negado.

Ele diz o que “pesou” na decisão do modelo... mas não diz o que fazer a respeito.

E se um dos atributos que mais pesou for algo que a pessoa não pode simplesmente mudar (idade, nacionalidade)?

Um gerador de contrafactuais sem nenhuma restrição pode sugerir “mude sua idade de 25 pra 65”, o que é matematicamente válido, mas impossível na vida real.

Um gerador de contrafactuais sem nenhuma restrição pode sugerir “mude sua idade de 25 pra 65”, o que é matematicamente válido, mas impossível na vida real.

A correção natural é usar o grafo causal: restringir a busca só a atributos *mutáveis*, e propagar mudanças pelos seus efeitos causais (ex: aumentar o tempo de emprego também deveria mudar a renda esperada).

Um gerador de contrafactuais sem nenhuma restrição pode sugerir “mude sua idade de 25 pra 65”, o que é matematicamente válido, mas impossível na vida real.

A correção natural é usar o grafo causal: restringir a busca só a atributos *mutáveis*, e propagar mudanças pelos seus efeitos causais (ex: aumentar o tempo de emprego também deveria mudar a renda esperada).

É a mesma lição do curso inteiro, aplicada em outro lugar: **o grafo carrega as suas suposições**, e ignorá-lo tem custo prático, não só teórico.

Notebook extra!

Caso queira aprofundar nesse assunto, veja o notebook extra #6.

9. Conclusão

- **Correlação $\neq$ causalidade:** o Paradoxo de Simpson mostrou isso com dados reais de vacinação, agregando errado, a vacina parecia piorar as coisas;

- **Correlação $\neq$ causalidade**: o Paradoxo de Simpson mostrou isso com dados reais de vacinação, agregando errado, a vacina parecia piorar as coisas;
- Um **grafo causal** formaliza suas suposições. Ele vem de especialistas, de descoberta automática, ou (o mais realista) dos dois juntos;

- **Correlação $\neq$ causalidade**: o Paradoxo de Simpson mostrou isso com dados reais de vacinação, agregando errado, a vacina parecia piorar as coisas;
- Um **grafo causal** formaliza suas suposições. Ele vem de especialistas, de descoberta automática, ou (o mais realista) dos dois juntos;
- **Causal Discovery** entrega uma classe de equivalência, não necessariamente a verdade.

- **Correlação $\neq$ causalidade**: o Paradoxo de Simpson mostrou isso com dados reais de vacinação, agregando errado, a vacina parecia piorar as coisas;
- Um **grafo causal** formaliza suas suposições. Ele vem de especialistas, de descoberta automática, ou (o mais realista) dos dois juntos;
- **Causal Discovery** entrega uma classe de equivalência, não necessariamente a verdade.
- **Identificar $\rightarrow$ Estimar $\rightarrow$ Refutar** é um pipeline, não uma fórmula única.

- **Correlação $\neq$ causalidade**: o Paradoxo de Simpson mostrou isso com dados reais de vacinação, agregando errado, a vacina parecia piorar as coisas;
- Um **grafo causal** formaliza suas suposições. Ele vem de especialistas, de descoberta automática, ou (o mais realista) dos dois juntos;
- **Causal Discovery** entrega uma classe de equivalência, não necessariamente a verdade.
- **Identificar $\rightarrow$ Estimar $\rightarrow$ Refutar** é um pipeline, não uma fórmula única.
- Causalidade **não exige um especialista o tempo todo**. Ex: seleção causal de atributos sem ninguém desenhando grafo à mão foi a diferença entre um modelo que quebra sob intervenção e um que não quebra.

Agora que você conhece um pouco mais sobre causalidade, talvez tenha percebido que ainda existem alguns desafios abertos:

- **Curva de aprendizado íngreme:** vocabulário, suposições e formalismo matemático são bem diferentes do que se vê em áreas como ML tradicional;

Agora que você conhece um pouco mais sobre causalidade, talvez tenha percebido que ainda existem alguns desafios abertos:

- **Curva de aprendizado íngreme:** vocabulário, suposições e formalismo matemático são bem diferentes do que se vê em áreas como ML tradicional;
- **Ferramentas fragmentadas:** você viu a tabela, quase ninguém faz descoberta, estimação e refutação ao mesmo tempo;

Agora que você conhece um pouco mais sobre causalidade, talvez tenha percebido que ainda existem alguns desafios abertos:

- **Curva de aprendizado íngreme:** vocabulário, suposições e formalismo matemático são bem diferentes do que se vê em áreas como ML tradicional;
- **Ferramentas fragmentadas:** você viu a tabela, quase ninguém faz descoberta, estimação e refutação ao mesmo tempo;
- **Escolher o algoritmo de descoberta certo é confuso:** PC? GES? LiNGAM? A resposta depende de premissas que muitas vezes você nem sabe se valem pro seu dataset;

Agora que você conhece um pouco mais sobre causalidade, talvez tenha percebido que ainda existem alguns desafios abertos:

- **Curva de aprendizado íngreme:** vocabulário, suposições e formalismo matemático são bem diferentes do que se vê em áreas como ML tradicional;
- **Ferramentas fragmentadas:** você viu a tabela, quase ninguém faz descoberta, estimação e refutação ao mesmo tempo;
- **Escolher o algoritmo de descoberta certo é confuso:** PC? GES? LiNGAM? A resposta depende de premissas que muitas vezes você nem sabe se valem pro seu dataset;
- **As ferramentas não conversam entre si:** montar um pipeline automatizado de ponta a ponta hoje é, na prática, trabalho manual de encaixar peças.

Foi exatamente pra atacar esses quatro problemas que desenvolvemos o **Causal-Nest** [1]: um framework que junta descoberta, validação de grafo, estimação e refutação num só pipeline, com interface web pra reduzir a barreira de entrada pra quem não é especialista.

Foi exatamente pra atacar esses quatro problemas que desenvolvemos o **Causal-Nest** [1]: um framework que junta descoberta, validação de grafo, estimação e refutação num só pipeline, com interface web pra reduzir a barreira de entrada pra quem não é especialista.

Não vamos entrar em detalhes aqui (é assunto pra outro curso!), mas se você curtiu a ideia e quiser se aprofundar:

Causal-Nest: A framework for automated causal discovery and inference

doi.org/10.1016/j.knosys.2026.116005

Knowledge-Based Systems, v. 343 (2026)

Boa parte do conteúdo teórico apresentado aqui foi originalmente escrito como o capítulo teórico da minha dissertação de mestrado na UFV [26], sob orientação de Fabrício Aguiar Silva e Marcus Henrique Soares Mendes.

Boa parte do conteúdo teórico apresentado aqui foi originalmente escrito como o capítulo teórico da minha dissertação de mestrado na UFV [26], sob orientação de Fabrício Aguiar Silva e Marcus Henrique Soares Mendes.

Se você quiser ver a mesma ideia de engenharia causal de atributos aplicada com mais profundidade num problema real, temos um estudo publicado no CBIC 2025 [27]: usamos o Causal-Nest pra guiar a engenharia de atributos na previsão de churn de clientes de telecom, e o ganho apareceu de forma consistente em vários modelos de ML diferentes.

- **Vídeo/slides complementares**
Causal Representation Learning - Uncovering the Hidden World de Prof. Kun Zhang
- **Demo interativa** (Hugging Face Spaces)
Demo interativa do trabalho de Zhang
- **Notebook extra — `notebooks/extras/5_heterogeneous_effects.ipynb`**
CATE com meta-learners (S/T/X-learner) e uma política de tratamento personalizada
- **Notebook extra — `notebooks/extras/7_counterfactual_explanations.ipynb`**
SHAP vs. DiCE, contrafactuais com e sem restrição causal

- [1] Gustavo F.V. de Oliveira, Fabrício A. Silva e Marcus H.S. Mendes. **“Causal-Nest: A framework for automated causal discovery and inference”**. Em: *Knowledge-Based Systems* 343 (2026), p. 116005. ISSN: 0950-7051. DOI: **10.1016/j.knosys.2026.116005**. URL: **<https://www.sciencedirect.com/science/article/pii/S0950705126007318>**.
- [2] Markus Kalisch e Peter Bühlman. **“Estimating high-dimensional directed acyclic graphs with the PC-algorithm.”**. Em: *Journal of Machine Learning Research* 8.3 (2007).
- [3] Dimitris Margaritis et al. **“Learning Bayesian network model structure from data”**. Tese de dout. School of Computer Science, Carnegie Mellon University Pittsburgh, PA, USA, 2003.
- [4] Ioannis Tsamardinos, Constantin F Aliferis, Alexander R Statnikov et al. **“Algorithms for large scale Markov blanket discovery.”**. Em: *FLAIRS*. Vol. 2. 2003, pp. 376–81.

Referências (ii)

- [5] Sandeep Yaramakala e Dimitris Margaritis. **“Speculative Markov Blanket Discovery for Optimal Feature Selection”**. Em: *ICDM '05: Proceedings of the Fifth IEEE International Conference on Data Mining*. IEEE Computer Society, 2005, pp. 809–812. DOI: **10.1109/ICDM.2005.40**.
- [6] Ioannis Tsamardinos, Laura E Brown e Constantin F Aliferis. **“The Max-Min Hill-Climbing Bayesian Network Structure Learning Algorithm”**. Em: *Machine Learning* 65.1 (2006), pp. 31–78. DOI: **10.1007/s10994-006-6889-7**.
- [7] David Maxwell Chickering. **“Optimal Structure Identification With Greedy Search”**. Em: *Journal of Machine Learning Research* 3 (2002), pp. 507–554.
- [8] Preetam Nandy, Alain Hauser e Marloes H Maathuis. **“High-dimensional consistency in score-based and hybrid structure learning”**. Em: *The Annals of Statistics* 46.6A (2018), pp. 3151–3183. DOI: **10.1214/17-AOS1654**.

- [9] Bryon Aragam e Qing Zhou. **“Concave penalized estimation of sparse Gaussian Bayesian networks”**. Em: *The Journal of Machine Learning Research* 16.1 (2015), pp. 2273–2328.
- [10] Changhe Yuan e Brandon Malone. **“Learning optimal Bayesian networks: A shortest path perspective”**. Em: *Journal of Artificial Intelligence Research* 48 (2013), pp. 23–65. DOI: **10.1613/jair.4039**.
- [11] Olivier Goudet, Diviyan Kalainathan, Philippe Caillou et al. **“Learning functional causal models with generative neural networks”**. Em: *Explainable and interpretable models in computer vision and machine learning* (2018), pp. 39–80.
- [12] Diviyan Kalainathan, Olivier Goudet, Isabelle Guyon et al. **“Structural agnostic modeling: Adversarial learning of causal graphs”**. Em: *Journal of Machine Learning Research* 23.219 (2022), pp. 1–62.

Referências (iv)

- [13] Shohei Shimizu, Patrik O Hoyer, Aapo Hyvärinen et al. **“A linear non-Gaussian acyclic model for causal discovery.”**. Em: *Journal of Machine Learning Research* 7.10 (2006).
- [14] Peter Bühlmann, Jonas Peters e Jan Ernest. **“CAM: Causal additive models, high-dimensional order search and penalized regression”**. Em: *The Annals of Statistics* 42.6 (2014), pp. 2526–2556. ISSN: 00905364. URL: **<http://www.jstor.org/stable/43556502>** (acesso em 30/10/2025).
- [15] Wai-Yin Lam, Bryan Andrews e Joseph Ramsey. **“Greedy relaxations of the sparsest permutation algorithm”**. Em: *Uncertainty in Artificial Intelligence*. PMLR. 2022, pp. 1052–1062.
- [16] Diviyan Kalainathan e Olivier Goudet. ***Causal Discovery Toolbox: Uncover causal relationships in Python***. 2019. DOI: **10.48550/ARXIV.1903.02278**.
- [17] Yujia Zheng, Biwei Huang, Wei Chen et al. ***Causal-learn: Causal Discovery in Python***. 2023. arXiv: **2307.16405 [cs.LG]**.

Referências (v)

- [18] Marco Scutari. “Learning Bayesian Networks with the bnlearn R Package”. Em: *Journal of Statistical Software* 35.3 (2010), pp. 1–22. DOI: **10.18637/jss.v035.i03**. URL: **<https://www.jstatsoft.org/index.php/jss/article/view/v035i03>**.
- [19] Joseph Ramsey e Bryan Andrews. “Py-Tetrad and RPy-Tetrad: A New Python Interface with R Support for Tetrad Causal Search”. Em: *Proceedings of the 2023 Causal Analysis Workshop Series*. Ed. por Erich Kummerfeld et al. Vol. 223. Proceedings of Machine Learning Research. PMLR, ago. de 2023, pp. 40–51. URL: **<https://proceedings.mlr.press/v223/ramsey23a.html>**.
- [20] Keli Zhang, Shengyu Zhu, Marcus Kalandar et al. “gCastle: A Python Toolbox for Causal Discovery”. Em: *arXiv preprint arXiv:2111.15155* (2021).
- [21] Amit Sharma e Emre Kiciman. “DoWhy: An End-to-End Library for Causal Inference”. Em: *Proceedings of the 36th Conference on Uncertainty in Artificial Intelligence (UAI)*. 2020, pp. 722–731.

- [22] Vasilis Syrgkanis, Greg Lewis, Miruna Oprescu et al. **“Causal Inference and Machine Learning in Practice with EconML and CausalML: Industrial Use Cases at Microsoft, TripAdvisor, Uber”**. Em: *Proceedings of the 27th ACM SIGKDD*. KDD '21. Virtual Event, Singapore: ACM, 2021, pp. 4072–4073. ISBN: 9781450383325. DOI: **10.1145/3447548.3470792**.
- [23] Huigang Chen et al. **“CausalML: Python Package for Causal Machine Learning”**. Em: *arXiv preprint arXiv:2002.11631* (2020).
- [24] QuantumBlack Labs. ***CausalNex***. **<https://github.com/mckinsey/causalnex>**. 2021.
- [25] Devansh Arpit, Matthew Howson et al. **“Salesforce CausalAI Library: A Fast and Scalable Framework for Causal Analysis of Time Series and Tabular Data”**. Em: *arXiv preprint arXiv:2301.10859* (2023).

- [26] Gustavo F.V. de Oliveira. **“Causal Discovery, Inference and Validation for Machine Learning Practitioners: An Accessible Framework Approach”**. Orientador: Fabrício Aguiar Silva; Coorientador: Marcus Henrique Soares Mendes. Dissertação de Mestrado. Universidade Federal de Viçosa, 2026.
- [27] Gustavo F.V. de Oliveira, Fabrício A. Silva e Marcus H.S. Mendes. **“Causality-Driven Feature Engineering for Enhanced Telecommunications Churn Prediction”**. Em: *Anais do XVII Congresso Brasileiro de Inteligência Computacional (CBIC 2025)*. Belo Horizonte, MG: SBIC, 2025, pp. 1–8. DOI: **10.21528/CBIC2025-1175578**.

Obrigado!

Gustavo Ferreira Viegas de Oliveira
gustavo.viegas@ufv.br

